

1과목 | 데이터 이해

01 다음 중 DIKW 피라미드에서 지식(Knowledge)에 해당되는 예시로 가장 적절한 것은?

- ① A마트는 100원에, B마트는 200원에 연필을 판매한다.
- ② A마트의 연필 가격이 더 싸다.
- ③ 상대적으로 저렴한 A마트에서 연필을 사야겠다.
- ④ A마트의 다른 상품들도 B마트보다 쌀 것이라고 판단한다.

02 다음 중 정성적 데이터(qualitative data)에 속하는 것은?

- ① 기상특보
- ② 온도
- ③ 풍속
- ④ 강수량

03 다음은 데이터베이스의 특징에 대한 설명이다. 가장 적절하게 연결된 것은?

- () 데이터 : 데이터베이스 내에 중복을 최소화하도록 데이터가 구성된다.
- () 데이터 : 컴퓨터가 접근 가능한 저장 매체에 데이터가 보관된다.
- () 데이터 : 여러 사용자가 다른 목적으로 데이터베이스의 정보를 공동으로 이용한다.
- () 데이터 : 데이터의 삽입, 갱신, 삭제로 항상 변화하면서 현재의 정확한 정보를 유지한다.

- ① 공유 - 저장 - 통합 - 변화되는
- ② 저장 - 통합 - 공유 - 변화되는
- ③ 통합된 - 저장 - 공유 - 변화되는
- ④ 통합된 - 공유 - 변화되는 - 저장

04 다음 중 빅데이터의 위기 요인으로 가장 적절하지 않은 것은?

- ① 사생활 침해
- ② 책임원칙 훼손
- ③ 데이터 오용
- ④ 분석 기술 부족

05 다음 중 빅데이터가 만드는 본질적인 변화로 적절하지 않은 것은?

- ① 질 → 양
- ② 상관관계 → 인과관계
- ③ 사전처리 → 사후처리
- ④ 표본조사 → 전수조사

06 빅데이터 시대의 위기 요인 중 사생활 침해에 대한 통제 방안으로 가장 적절한 것은?

- ① 알고리즘 접근 허용
- ② 동의가 아닌 사용자의 책임으로
- ③ 결과 기반 책임 원칙 고수
- ④ 사용자 정보의 무제한 공유 허용

07 다음 중 빅데이터를 다각적으로 분석하여 인사이트를 도출하는 데이터 사이언티스트의 필요 역량으로 가장 적절하지 않은 것은?

- ① 설득력 있는 스토리텔링 능력
- ② 통찰력 있는 분석 능력
- ③ 뉴럴 네트워크 최적화 능력
- ④ 다분야 간 커뮤니케이션 능력

08 다음 중 빅데이터 현상이 출현하게 된 배경과 가장 거리가 먼 것은?

- ① 하둡 등 분산처리 기술의 발전
- ② M2M, IoT와 같은 통신 기술의 발전
- ③ 다양하게 활용되는 정형 데이터의 확산
- ④ SNS의 급격한 확산

09 다음 중 복잡한 관계를 얼마나 효과적이고 신뢰성 있게 관리하는가에 대한 빅데이터 가치 패러다임으로 가장 적절한 것은?

- ① 연결(Connection)
- ② 디지털화(Digitalization)
- ③ 에이전시(Agency)
- ④ 관리(Management)

10 다음 중 빅데이터의 효능으로 가장 적절하지 않은 것은?

- ① 고객에게 획일화된 서비스 제공
- ② 개인화된 마케팅 전략 수립
- ③ 실시간 데이터 분석을 통한 의사결정 지원
- ④ 예측 분석을 통한 미래 트렌드 예측

2과목 | 데이터 분석 기획

11 다음 중 KDD 분석방법론의 단계로 가장 적절한 것은?

- ① Selection-Preprocessing-Transformation-Data Mining-Interpretation/Evaluation
- ② Planning-Preprocessing-Transformation-Data Mining-Interpretation/Evaluation
- ③ Preprocessing-Selection-Transformation-Data Mining-Interpretation/Evaluation
- ④ Selection-Transformation-Preprocessing-Data Mining-Interpretation/Evaluation

12 분석 과제 발굴을 위한 접근 방식에 대한 설명으로 가장 적절하지 않은 것은?

- ① 분석할 대상이 명확한 경우 상향식 접근 방식이 적절하다.
- ② 디자인 사고 프로세스는 상향식 접근과 하향식 접근이 반복적으로 수행된다.
- ③ 하향식 접근 방식은 문제가 주어지고 이에 대한 해법을 찾기 위한 과정이 단계화된 것이다.
- ④ 일반적으로 상향식 접근 방식은 비지도 학습 방식으로 수행된다.

13 빅데이터의 4V에서 비즈니스 효과 측면에 해당하는 것은?

- ① Volume
- ② Variety
- ③ Value
- ④ Velocity

14 다음 중 분석준비도의 영역에 해당되지 않는 것은?

- ① 분석 기법
- ② 분석 문화
- ③ IT 인프라
- ④ 분석 비용

15 다음 중 협의의 데이터 분석 플랫폼 구성 요소로 가장 적절한 것은?

- ① 하드웨어
- ② 분석 서비스 제공 API
- ③ 분석 라이브러리
- ④ 분석 서비스 제공 엔진

16 분석 과제를 추진할 때 시급성의 판단 기준으로 가장 적절한 것은?

- ① 데이터 획득, 저장, 가공 비용
- ② 조직의 분석수준
- ③ 분석 난이도
- ④ 전략적 중요도

17 분석 주제는 분석 대상과 분석 방법에 따라 다음의 4가지 유형으로 나눌 수 있다. 다음 중 분석 대상을 모르지만, 분석 방법을 아는 경우의 유형으로 가장 적절한 것은?

- ① 최적화(Optimization)
- ② 솔루션(Solution)
- ③ 통찰(Insight)
- ④ 발견(Discovery)

18 다음 중 CRISP-DM의 업무 이해 단계의 태스크로 가장 적절한 것은?

- ① 전개 계획 수립, 모니터링과 유지보수 계획 수립, 프로젝트 종료 보고서 작성, 프로젝트 리뷰
- ② 업무 목적 파악, 상황 파악, 데이터 마이닝 목표 설정, 프로젝트 계획 수립
- ③ 초기 데이터 수집, 데이터 기술 분석, 데이터 탐색, 데이터 품질 확인
- ④ 분석용 데이터셋 선택, 데이터 정제, 분석용 데이터셋 편성, 데이터 통합, 데이터 포매팅

19 다음에서 설명하는 IT 부문의 내용에 맞는 성숙 단계로 가장 적절한 것은?

분석 협업환경 분석, Sandbox 프로세스, 내재화 빅데이터 분석

- ① 도입 단계
- ② 활용 단계
- ③ 확산 단계
- ④ 최적화 단계

20 다음 중 분석 과제 관리를 위한 고려사항이 아닌 것은?

- ① 데이터 크기
- ② 분석 속도
- ③ 정확성
- ④ 분석 비용

3과목 | 데이터 분석

21 다음 중 시계열의 분해 요소로 가장 적절하지 않은 것은?

- ① 추세 요인
- ② 계절 요인
- ③ 교호 요인
- ④ 불규칙 요인

22 다음 중 변수선택법에 대한 설명으로 가장 적절하지 않은 것은?

- ① 전진 선택법은 상수항을 제외한 모든 설명변수를 제거 후 추가하는 방법이다.
- ② 후진 제거법은 모든 변수를 포함한 후 상수항만 남을 때까지 변수 제거를 반복하는 방법이다.
- ③ 단계별 선택법은 변수를 추가할 때마다 기존 변수들의 중요도를 재평가하여 필요시 제거하는 방식이다.
- ④ 변수 선택법은 데이터에 따라 다르게 작용할 수 있으며, 항상 최적의 모델을 보장하지는 않는다.

23 다음 중 이상값 검정을 활용한 응용 시스템으로 적절한 것은?

- ① 교차판매 시스템

- ② 고객 세분화 시스템
- ③ 장바구니 분석 시스템
- ④ 부정 사용방지 시스템

24 아래 보기와 같은 만족도에 대한 5점 척도를 조사하고자 할 때 사용되는 척도는?

〈아래〉
1. 매우 불만족
2. 불만족
3. 보통
4. 만족
5. 매우 만족

- ① 명목 척도
- ② 구간 척도
- ③ 비율 척도
- ④ 순서 척도

25 귀무가설이 맞다고 가정할 때 얻은 결과보다 극단적인 결과가 실제로 관측될 확률은 무엇인가?

- ① α
- ② p-value
- ③ β
- ④ $1-\alpha$

26 다음 회귀분석의 결과에서 Outstate의 t값을 구하는 계산식으로 가장 적절한 것은?

Coefficients:		
	Estimate	Std. Error
(Intercept)	41.6291341	2.5177761
Outstate	0.0020537	0.0001692

- ① $0.0020537/0.0001692$
- ② $0.0020537 \times 0.0001692$
- ③ $0.0001692/0.0020537$
- ④ $0.0020537 + 0.0001692$

27 다음 중 A 질병을 진단받은 사람 중 실제로 A 질병에 걸렸을 확률로 가장 적절한 것은?

- 전체 중 A 질병을 가진 사람: 10%
- 전체 중 A 질병을 진단받은 사람: 20%
- 해당 질병을 가진 사람의 90%는 질병이 있다고 진단된다.

- ① 9/10
- ② 2/9
- ③ 1/10
- ④ 9/20

28 다음 중 인공신경망(Artificial Neural Network, ANN)에 대한 설명으로 가장 적절하지 않은 것은?

- ① 뉴런이 많으면 과소적합, 뉴런이 적으면 과대적합 문제가 발생한다.
- ② 활성화 함수는 비선형성을 모델에 도입하기 위해 사용된다.
- ③ 입력층, 은닉층, 출력층으로 구성되며 각 층은 뉴런으로 이루어져 있다.
- ④ 인공신경망은 학습을 통해 가중치를 업데이트하여 최적화된 모델을 만든다.

29 다음 중 이상값(outlier) 처리에 대한 설명으로 가장 적절하지 않은 것은?

- ① 범위의 경우 이상값 존재 시 값이 커진다는 단점이 있다.
- ② ESD(Extreme Studentized Deviate)는 다중변수의 이상값을 찾는다.
- ③ 4분위수는 이상값에 민감하지 않다.
- ④ 단일변수 이상값을 제거하거나 유지할 때는 분석 시간 제약을 고려해야 한다.

30 다음 중 통계 지표에 대한 설명으로 가장 적절하지 않은 것은?

- ① 분산은 각 데이터 값이 평균에서 얼마나 떨어져 있는지를 나타내는 지표이다.
- ② 중앙값은 데이터의 값들을 크기 순으로 정렬했을 때, 가운데 위치한 값 또는 두 값의 평균을 의미한다.
- ③ 왜도(Skewness)는 데이터 분포가 평균을 기준으로 비대칭적인 정도를 나타내는 지표이다.
- ④ 평균 절대 오차(MAE)는 중앙값과 변수 사이의 차이로 구성된다.

31 다음 중 다중공선성의 해결 방법으로 가장 적절하지 않은 것은?

- ① 중요도가 낮으면서 상관계수가 높은 변수를 제거한다.
- ② 구조적 다중공선성 문제가 있는 경우, 독립변수를 평균 중심화하여 조정한다.
- ③ 상관계수를 낮추기 위해 변수 값을 조정한다.
- ④ VIF를 이용하여 다중공선성 유무를 판단한다.

32 다음 중 다중 선형회귀모형에서 유의성을 평가할 때 가장 적절한 것은?

- ① F-통계량
- ② t-통계량
- ③ 카이제곱 통계량
- ④ Z-통계량

33 다음은 남학생과 여학생이 좋아하는 과일에 대한 빈도교차표이다. 전체에서 1명을 뽑았을 때, 그 학생이 사과를 좋아할 확률은 얼마인가?

	사과	딸기
남	30	20
여	10	40

- ① 3/10
- ② 4/10
- ③ 5/10
- ④ 6/10

34 다음 중 자기회귀 모형에서 AR(1)과 AR(2)가 의미하는 것으로 가장 적절한 것은?

- ① AR(1)은 선형 시계열 데이터를 사용, AR(2)는 비선형 시계열 데이터를 사용한다.
- ② AR(1)은 단기 메모리를 사용, AR(2)는 장기 메모리를 사용한다.
- ③ AR(1)은 정상 시계열 모형, AR(2)는 비정상 시계열 모형이다.
- ④ AR(1)은 직전 시점의 데이터를, AR(2)는 직전 두 시점의 데이터를 사용하여 분석한다.

35 모집단이 정규분포를 따를 때, 신뢰구간 95%가 다음과 같이 계산된다. 다음 중 가장 적절하지 않은 설명은 무엇인가?

$$0.5 \pm 1.96 / \sqrt{100}$$

- ① 신뢰구간을 99%로 변경하면 1.96 대신 2.58을 사용한다.
- ② 표본평균이 0.5이다.
- ③ 모집단의 평균값이 신뢰구간에 포함되지 않을 수 있다.
- ④ 동일한 모집단에서 같은 방식으로 표본을 추출하고 같은 방식으로 신뢰구간을 추정하면 동일한 값이 나온다.

36 다음 중 결측값 처리 방법에 대한 설명으로 가장 적절하지 않은 것은?

- ① 완전 분석법은 모든 결측값을 삭제하므로 너무 많은 자료가 삭제 될 수 있다.
- ② 평균 대체법은 결측값을 평균으로 대체하는 것으로 대표적으로 조건부 평균 대체법과 비조건부 평균 대체법이 있다.
- ③ 단순 확률 대체법은 평균 대체법의 추정량 표준오차의 과소추정을 보완하고자 고안된 방법으로, 회귀모형을 이용한다.
- ④ 다중 대체법은 단순 대체법을 한 번 하지 않고 여러번 대체를 통해 가상적 완전 자료를 만드는 방법이다.

37 다음 중 시계열 분석에 대한 설명으로 가장 적절하지 않은 것은?

- ① 차분은 현재 시점 자료의 값에서 여러 시점전의 값을 빼주는 방법이다.
- ② 자기회귀모형(AR)은 과거 값들을 이용하여 현재 값을 예측하는 방법이다.

- ③ 이동평균모형(MA)은 과거의 오차 항들을 이용하여 현재 값을 예측하는 방법이다.
- ④ 정상성을 확보하기 위해 시계열 데이터를 차분하거나 로그 변환을 사용할 수 있다.

38 다음 중 통계 모형의 평가지표에 대한 설명으로 가장 적절하지 않은 것은?

- ① 수정된 결정계수는 결정계수의 단점을 보완한 것이다.
- ② Mallows Cp는 모델에 포함된 변수의 수와 MSE를 고려하여 모델의 적합도와 복잡성 사이의 균형을 평가한다.
- ③ AIC는 모델의 복잡도에 따라 벌점을 부과하는 방법이다.
- ④ BIC는 Bayesian 이론을 이용하여 모델에 가중치를 부과하는 방법이다.

39 다음 중 DBSCAN에 대한 설명으로 가장 적절하지 않은 것은?

- ① 임의 형태의 군집으로 분류하는데 유용하다.
- ② 밀도 기반의 군집화 방법으로 노이즈 데이터를 처리할 수 있다.
- ③ K-means와 같이 초기 군집 수를 미리 설정해야 한다.
- ④ 다차원 자료의 경우 '차원의 저주'로 인해 유용하지 않다.

40 다음 중 혼합분포 군집분석에서 모수를 찾을 때 이용하는 방법은 무엇인가?

- ① 최대우도 추정법

- ② K-평균 알고리즘
- ③ EM 알고리즘
- ④ 최소제곱법

41 다음 중 아래 오분류표에 대한 오분류율은 얼마인가?

		예측치	
		TRUE	FALSE
실제값	TRUE	30	60
	FALSE	70	40

- ① 13/20
- ② 7/20
- ③ 3/10
- ④ 7/11

42 다음 중 Apriori 알고리즘의 특징으로 가장 적절한 것은?

- ① 최소 지지도 이상의 빈발 항목 집합을 찾는다.
- ② 항목 집합의 크기가 증가할수록 계산 복잡도가 감소한다.
- ③ 모든 가능한 항목 집합을 탐색하여 빈발 항목 집합을 찾는다.
- ④ 회귀 분석을 사용하여 항목 간의 관계를 분석한다.

43 다음 중, A를 구매했을 때 B를 구매하는 확률이, B를 구매하는 전체 확률에 비해 얼마나 더 높아졌는지를 나타내는 지표는 무엇인가?

- ① 지지도
- ② 신뢰도
- ③ 향상도
- ④ 재현율

44 다음 중 의사결정나무에서 현재의 마디(노드)에서 더 이상 분리되지 않고 해당 마디를 끝으로 처리하게 되는 규칙을 의미하는 것은?

- ① 오즈
- ② 활성함수
- ③ 가지치기
- ④ 정지규칙

45 다음 중 앙상블 모형에 해당하지 않는 것은?

- ① 배깅
- ② 부스팅
- ③ 스택킹
- ④ 시그모이드

46 다음 중 신용카드 고객의 파산 여부(Yes/No)를 예측하기에 가장 적절하지 않은 방법은?

- ① 선형 회귀분석
- ② 로지스틱 회귀분석
- ③ 랜덤 포레스트
- ④ 서포트벡터 머신

47 다음 중 지도학습의 기법으로 볼 수 없는 것은?

- ① 로지스틱 회귀분석
- ② 의사결정나무
- ③ 인공신경망
- ④ SOM

48 다음 중 의사결정나무 모형 구축 시 분류나무의 분류 기준으로 가장 적절하지 않은 것은?

- ① 카이제곱 통계량
- ② 엔트로피 지수
- ③ 지니지수
- ④ 분산의 감소량

49 다음 중 군집분석에서 최적의 군집 수를 계산하는 방법으로 가장 적절한 것은?

- ① 엘보우 방법
- ② 상관계수
- ③ 유클리드 거리
- ④ ROC

50 다음 중 주어진 회귀분석 결과에 대한 설명으로 가장 적절하지 않은 것은?

```
> summary(lm(sales~TV+radio+TV:radio,data=advertising))
```

Call:
lm(formula = sales ~ TV + radio + TV:radio, data = advertising)

Residuals:

Min	1Q	Median	3Q	Max
-6.3366	-0.4828	0.1831	0.5948	1.5246

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	6.750e+00	2.479e-01	27.233	<2e-16 ***
TV	1.918e-02	1.584e-03	12.699	<2e-16 ***
radio	2.886e-02	8.905e-03	3.241	0.0014 **
TV:radio	1.886e-03	5.242e-05	28.727	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.9435 on 196 degrees of freedom
Multiple R-squared: 0.9678, Adjusted R-squared: 0.9673
F-statistic: 1963 on 3 and 196 DF, p-value: < 2.2e-16

- ① 통계 모형이 유의하다.
- ② TV와 Radio 간의 상호작용 효과는 유의하다.
- ③ TV가 1 증가할 때, Radio와 상관없이 Sales가 증가한다.
- ④ 모형의 설명력은 약 97%이다.